

面向多模态几何推理的可信校准定理路线

精简版 arXiv Demo 报告

Anonymous Demo Draft

2026 年 6 月

摘要

中间几何语言常被认为可以提升多模态大模型的几何解题能力，但我们的实验显示，这个假设并不完整。在 Geometry3K 上，把 GDP-4B 自动结构语言追加到原始图像后，并不能稳定提升 Qwen3-VL；即使是干净的 Geometry3K oracle predicates，也可能低于 image-only raw 输入。真正有用的信号更具体：当定理路线与目标量绑定时，它能修正 raw 错误；但同一个 route 通道也可能破坏原本正确的视觉答案。因此，我们把 theorem route 重新定义为“不确定干预”，而不是可信提示词。在 601 题 Geometry3K route 对比中，旧 route generator 只带来 +0.998% 的净提升，因为它修正 40 个 raw 错误，同时破坏 34 个 raw 正确答案；compact route generator 的净提升为 +1.83%，对应 27 个 win 和 16 个 loss。本文形式化这种 win-loss tradeoff，把理想 route gate 写成选择性风险最小化问题，并主张下一步不应继续设计更长的中间语言，而应训练能判断 route 是否与目标绑定、是否会帮助下游 MLLM 的 verifier。

1 研究动机

几何视觉问答要求模型读取图形、绑定标签和数值、选择定理路线，并计算目标量。因此，一个自然想法是添加中间语言，例如点线关系、结构事实或定理提示。然而，我们的结果表明，中间文本不是单调有益的。它可以补充缺失结构，也可以覆盖模型本来正确的视觉判断。

因此，本文主线收束为一个问题：

MLLM 什么时候应该相信生成的 theorem route，什么时候应该忽略它？


这个主线比“设计一种更长的中间语言”更清楚。核心证据只有三类：第一，结构语言不是 plug-and-play；第二，route 同时产生 wins 和 losses；第三，route selector 应该用反事实效果训练和评估。

2 结构语言不是天然有效


表 1 说明，GDP-4B 自动结构不够可靠：在 Geometry3K-300 上，它把准确率从 52.67% 降到 51.33%。construction-aware oracle plan 提高到 55.67%，但它依赖干净标注和目标条件化规则。在完整 601 题 Geometry3K 测试上，即使是 clean oracle formal predicates 也不能稳定提升 Qwen3-VL；谨慎筛选后的 top-6 oracle 版本也只是与 raw 持平。

表 1: 代表性结构语言实验。除纯文本 probe 外，所有条件都包含原始图像、题干和选项。

条件	正确数	总数	准确率
Geometry3K-300 raw	158	300	52.67%
Geometry3K-300 image+GDP	154	300	51.33%
Geometry3K-300 construction plan	167	300	55.67%
Geometry3K-601 raw	325	601	54.08%
Geometry3K-601 oracle full	318	601	52.91%
Geometry3K-601 oracle top-6 cautious	325	601	54.08%
Geometry3K-601 corrupted trusted	314	601	52.25%



(a) Geometry3K-300。



(b) Geometry3K-601 trust test。

图 1: 中间结构语言并不自动有益。GDP 自动结构在 Geometry3K-300 上低于 raw；完整 oracle predicates 在 601 题测试上也低于 raw。

Answer-steering 压力测试进一步说明，结构语言不是普通附加信息，而是一个高影响力控制通道。当结构文本被包装成 trusted 并指向某个答案时，MLLM 往往会跟随它。故意错误的 trusted structure 会把准确率降到 7.5%，答案跟随率约为 90%。

3 定理路线有用，但也有风险

最清楚的正向信号来自 theorem-route guidance，而不是冗长的几何事实描述。Route 是类似“使用平行对应角，然后使用相似三角形比例”的紧凑提示，不是完整解答。下游求解器仍然接收原始图像。

表 2 支持一个更窄但更扎实的结论：定理路线可以帮助模型，但它的价值取决于修正了多少 raw 错误，以及破坏了多少 raw 正确答案。Compact route 在 601 题上比旧 route 更稳定，因为它减少了 route-induced loss。旧 generator 有时会重复同一个定理很多次，或者输出“定理本身正确但与目标无关”的路线。Compact route 通过长度约束和去重减少了这种问题，但仍然不能完全解决错误 route 和过度信任。




图 2: 答案诱导压力测试。被包装为 trusted 的错误结构可以压过图像和题干, 因此 route 和 structure 通道必须校准。

表 2: 定理路线实验。Win/loss 均相对 image-only 预测计算。

评测	条件	准确率	Win	Loss
Geometry3K-150	image only	50.67%	—	—
Geometry3K-150	generated route	54.67%	16	10
Geometry3K-200	image only	52.0%	—	—
Geometry3K-200	old route	54.5%	15	10
Geometry3K-200	compact route	56.0%	12	4
Geometry3K-601	image only	53.74%	—	—
Geometry3K-601	old route	54.74%	40	34
Geometry3K-601	compact route	55.57%	27	16

4 为什么 route 效果差异很大

图 3 展示了差异机制。在题 2408 中, 目标是 NZ , 关键关系是 $MN \parallel YZ$, 从而得到相似三角形和比例关系。旧 route 只给“line addition”, 不足以求出 XZ ; compact route 指向平行角和相似三角形比例, 模型答对。

题 2474 中, raw 本来正确。题目给的是平行四边形相邻角, 因此需要相邻角互补; route 却强调对角相等。这个定理在平行四边形中是真的, 但不是当前已知量和目标量所需的路线。这个例子说明: **theorem validity 不等于 route usefulness**。

题 2545 是另一种情况。图是多个半圆构成的阴影面积问题。old route 粗略地提示“circle area formula”, 反而足以激活正确面积计算; compact route 提到了更复杂的 segment-area/power relation, 和图形目标不贴合。题 2605 中, compact route 给圆角问题额外加入 external arc theorem, 干扰了更简单的圆周角和角差关系。




图 3: 代表性 route 分歧案例。关键不是 route 长度, 而是 route 是否绑定到目标量。

5 将 route 视为不确定干预

对第 i 道题, 令 x_i 表示图像、题干和选项, y_i 表示正确答案, r_i 表示生成路线, $f_0(x_i)$ 表示 image-only 预测, $f_r(x_i, r_i)$ 表示 route-conditioned 预测。定义 route 的反事实效应:

$$\Delta_i(r) = \mathbf{1}[f_r(x_i, r_i) = y_i] - \mathbf{1}[f_0(x_i) = y_i]. \quad (1)$$

其中 $\Delta_i = +1$ 是 route win, $\Delta_i = -1$ 是 route loss, $\Delta_i = 0$ 是 neutral。总体收益为:

$$\text{Gain}(r) = \frac{1}{N} \sum_i \Delta_i(r) = \frac{W(r) - L(r)}{N}. \quad (2)$$

所以 old route 的收益是 $(40 - 34)/601 = 0.998\%$, compact route 的收益是 $(27 - 16)/601 = 1.83\%$ 。

Route selection 本质上是选择性预测问题。策略 π 在

$$a_i \in \{\text{RAW}, \text{ROUTE}\}$$

中选择一个动作, 最终预测为:

$$\hat{y}_i = \begin{cases} f_0(x_i), & \pi(x_i, r_i) = \text{RAW}, \\ f_r(x_i, r_i), & \pi(x_i, r_i) = \text{ROUTE}. \end{cases} \quad (3)$$

理想 gate 最小化:

$$\min_{\pi} \frac{1}{N} \sum_i \mathbf{1}[\hat{y}_i \neq y_i], \quad (4)$$

并且只有当 route-conditioned 预测比 raw 更可能正确时才使用 route:

$$P(f_r(x_i, r_i) = y_i \mid x_i, r_i) > P(f_0(x_i) = y_i \mid x_i). \quad (5)$$

这解释了为什么只判断定理“看起来合理”的 verifier 不够。Verifier 必须预测真实下游反事实: 使用 route 是否比 raw 更好。

为了避免退化成提示词判断，可以定义目标绑定分数。设几何图为 $G_i = (V_i, E_i, R_i)$ ，目标量为 τ_i 。Route $r_i = (t_1, \dots, t_K)$ 中每个定理有前提 $\mathcal{P}_k$ 和结论 $\mathcal{Q}_k$ 。一个简单的绑定分数为：

$$B(r_i, \tau_i, G_i) = \lambda_1 \text{cov}\left(\tau_i, \bigcup_k \mathcal{Q}_k\right) + \lambda_2 \text{cov}\left(K_i, \bigcup_k \mathcal{P}_k\right) - \lambda_3 \text{miss}(r_i, G_i), \quad (6)$$

其中 K_i 是题干已知量。该分数奖励结论触达目标、前提使用已知量、对象被图像或 parse 支持的 route。

最后，设 p_h 是 route 修正 raw 错误的概率， p_c 是 route 破坏 raw 正确答案的概率，则：

$$\mathbb{E}[\Delta] = p_h - p_c.$$

若 gate 接受 helpful route 的概率为 α ，错误接受 harmful route 的概率为 β ，则：

$$\mathbb{E}[\Delta_{\text{gate}}] = \alpha p_h - \beta p_c, \quad \text{有效 gating 需要 } \frac{\alpha}{\beta} > \frac{p_c}{p_h}. \quad (7)$$

之前 verifier 没有明显提升，可以理解为没有充分降低 β ：很多 harmful route 在表面上仍然像合理定理。

6 哪些内容应删除或后置

长版 demo 中有些实验对开发有用，但不适合作为主论文核心。GDP-to-construction-plan generator 在 200 题上只有 +1.0 个百分点的小幅收益，更像 preliminary engineering attempt。FormalGeo partial checkpoint 不应作为主结果出现，除非完整实验结束。MathVista transfer 可以作为边界条件，但会分散本文“几何定理路线可信校准”的主线。这些内容更适合放到附录，或暂时从主稿删除。

7 下一步

下一步应训练 target-binding route verifier，并用反事实标签监督：

$$\text{raw wrong, route correct} \rightarrow \text{USE_ROUTE}, \quad \text{raw correct, route wrong} \rightarrow \text{REJECT_ROUTE}.$$

Hard negatives 应该是“局部看起来合理但目标不匹配”的路线，例如平行四边形题中使用真实但不服务当前相邻角方程的定理。评测也不应只报告 accuracy，还应报告 win、loss、route acceptance rate 和 route-helpfulness confidence 的校准情况。

8 结论

核心结论不是“中间几何语言总能提升 MLLM”。相反，很多结构语言并不能提升，甚至会伤害模型。更强的结论是：定理路线只有作为可信校准的不确定干预时才有价值。Compact route 在

Geometry3K 上提升 Qwen3-VL，是因为它减少了 route-induced loss，同时保留了足够的 route-induced win。下一步真正有研究价值的贡献应是 target-binding verifier 和 counterfactual evaluation protocol，而不是继续设计更长的 prompt 格式。