

面向多模态大模型的可信校准几何中间语言

Geometry3K 与 MathVista 实验的中文 arXiv Demo 报告

Anonymous Demo Draft

2026 年 6 月

摘要

几何题中的中间结构化语言常被认为可以连接“图形感知”和“符号推理”。我们的实验显示，结论要更谨慎：结构化语言不是天然有用，关键在于它是否可靠、是否和目标相关，以及模型是否应该相信它。在 300 题 Geometry3K 子集上，给 Qwen3-VL-8B 添加 GDP-4B 自动几何语言后，准确率从 raw 的 52.67% 降到 51.33%；而使用基于 Geometry3K 标注和规则生成的 construction-aware oracle 语言，准确率提高到 55.67%。但在完整 601 题 Geometry3K 测试集上，即使是 Geometry3K oracle formal predicates 也不能稳定提升模型：full oracle structure 为 52.91%，低于 raw 的 54.08%；经过筛选的 cautious top-6 版本也只是与 raw 持平。压力测试进一步说明，若把错误结构化语言包装成“可信事实”，模型会严重被带偏：错误答案引导条件下准确率降到 7.5%，模型约 90% 的时候会跟随错误结构。因此，最新实验从“更长的结构描述”转向“更紧凑的定理路线提示”：我们用 FormalGeo 的 theorem sequence 监督训练 Qwen3-1.7B LoRA route generator，让它从 GDP-4B 自动解析生成可能的定理路线，再把原始图像、题干和 generated route 一起输入 Qwen3-VL。在完整 601 题 Geometry3K route 评测中，compact route generator 将 Qwen3-VL 从 raw 的 53.74% 提高到 55.57%，同时把旧 route generator 造成的 route-induced loss 从 34 个样例降到 16 个样例。当前结论更具体：定理路线先验有潜力，但必须配合生成可靠性和信任校准，减少结构语言带来的错误引导。

1 研究动机

几何视觉问答同时需要图形感知和数学推理。多模态大模型不仅要识别点、线、角、圆、切线、平行、垂直等视觉关系，还要判断题目目标、选择合适定理并完成计算。因此，一个自然假设是：如果先用图形解析器输出中间结构化语言，再让 MLLM 解题，模型可能更容易推理。

我们的结果只在严格条件下支持这个假设。目前表现最好的语言是 `construction_plan`，它不是普通的图形描述，而是利用 Geometry3K oracle 标注，通过规则生成“已知事实、辅助构造候选、定理路线和执行约束”。在同一组 Geometry3K-300 上，它把准确率从 raw 的 52.67% 提高到 55.67%。相反，GDP-4B 自动结构和几种简单结构化格式并不能稳定提升。pairwise flips 可以解释这个现象：有用结构能修正一部分 raw 错误，但噪声结构或被过度信任的结构也会破坏原本正确的视觉答案。




图 1: 可信校准中间语言的概念流程。当前最好结果来自 oracle-guided construction plan。下一步应训练能自动产生可靠、目标相关 construction language 的模型，并校准 MLLM 应该相信多少。

因此，更值得研究的方向不是继续堆更长的中间语言，而是**可信校准的几何中间语言**：每条结构事实都应该带有可靠性、目标相关性，以及是否与图像或题干冲突的判断。

2 实验中的中间语言

我们比较了原始图像输入和多种结构化语言。除 text-only probe 外，所有结构化条件都包含原始图像、题干和选项。

Raw. 模型只接收原始题图、题干和选项。这是判断结构化语言是否真的有帮助的基线。

GDP 自动语言. GDP-4B 自动把图形解析为几何结构事实，然后 Qwen3-VL 接收“图像 + 题干 + 选项 + GDP 输出”。这是我们最接近论文中“GDP language 可以提升 MLLM”的复现实验。

Structured facts. 使用 Geometry3K oracle formal predicates，并按目标相关性和关系类型做排序与压缩。它测试的是：干净符号事实本身是否足够有用。

Perception graph. 把 oracle predicates 分组为目标、可见对象、数值标签、空间关系等，形式更接近感知图。

Construction plan. 在 oracle predicates 基础上加入辅助构造候选和定理路线提示。它由 Geometry3K 标注和手写规则生成，不是模型输出。目前这是效果最好的结构语言，但仍然依赖 oracle。

GeoGuide-style variants. 参考近期几何推理论文中的 solver-like prompt，设计了一个更强推理框架和一个更谨慎的冲突处理框架。

3 construction_plan 如何产生

当前的 construction_plan 来自 Geometry3K 标注和手写规则，不是模型直接输出。它读取题目文本、dissolved-text 和 diagram logic forms，按目标重叠度和关系类型排序 predicates，然后

表 1: Geometry3K-300 主结果。

条件	正确数	总数	准确率
raw	158	300	52.67%
image+GDP	154	300	51.33%
construction_plan	167	300	55.67%

补充辅助构造候选和定理路线提示。

Listing 1: construction-aware intermediate language 的模板。

Construction-aware intermediate language.

[KNOWN FACTS]

- shortened/ranked Geometry3K predicates

[AUXILIARY CONSTRUCTION CANDIDATES]

- Circle construction: connect center to tangent point/chord endpoint...
- Similarity construction: identify corresponding vertices...
- Right-triangle construction: drop or identify a perpendicular...

[THEOREM ROUTE]

- Check right-triangle, perpendicular-angle, Pythagorean, or trig relations.
- Use circle angle, radius, chord, tangent, or arc rules.

[EXECUTION]

- Pick at most one useful construction; do not invent unsupported geometry.
- After each visual/theorem step, re-check the relevant image mark or label.
- Form the equation or comparison, compute the target, then choose one option.

它与 GDP 语言有两个核心区别。第一，GDP 是自动 parser 输出，可能漏检关系或产生幻觉关系；`construction_plan` 当前由 oracle 标注和规则生成，事实来源更干净。第二，GDP 主要描述检测到的对象和关系，而 `construction_plan` 是目标条件化、定理导向的：它不仅告诉模型“图里有什么”，还提示“这题可能需要哪类辅助构造和定理路线”，同时要求模型重新检查图像证据。

4 主要实验结果

在同一组 300 道 Geometry3K 题上，`construction_plan` 得到 167/300，raw 为 158/300，image+GDP 为 154/300。pairwise 结果比平均准确率更有解释力：`construction_plan` 修正了 19 个 raw 错误，但也破坏了 10 个 raw 原本正确的问题，净收益为 +9；GDP 则相反，修正 10 个但破坏 14 个，净收益为 -4。

跨数据集结果更弱。在 Geometry3K-300 加 MathVista-MC-300 的组合上，raw 总体准确




图 2: Geometry3K-300 主结果。GDP-4B 自动结构低于 raw，而 oracle-guided construction-aware language 比 raw 高 3.00 个百分点，比 image+GDP 高 4.34 个百分点。

表 2: 相对 raw 的 pairwise flips。

条件	修正 raw 错误	破坏 raw 正确	净变化
image+GDP	10	14	-4
construction_plan	19	10	+9

率为 62.00%，`construction_plan` 为 62.50%。但单独看 MathVista-MC-300，raw 为 71.33%，`construction_plan` 为 69.33%。这说明 construction-aware structure 更适合几何专门任务，尤其是 oracle predicates 和定理提示能与题目目标匹配的情况。

5 可信校准实验

这个实验覆盖 601 道 Geometry3K 测试题。核心结果是负面的，但很有价值：full oracle structure 并不是 plug-and-play 的提升方案，它得到 318/601，低于 raw 的 325/601。top-6 cautious 版本与 raw 持平，并优于 full oracle structure，说明筛选和冲突提示有帮助。然而，corrupted trusted structure 降到 314/601，并且破坏 23 个 raw-correct case，只修正 12 个 raw-wrong case。

这支持一个更窄但更扎实的结论：结构事实在被正确筛选和正确包装时可能有用，但 MLLM 很容易过度相信结构化文本。因此，一个真正有用的系统应该判断“每条事实是否值得相信”，而不是简单追加所有事实。

表 3: 完整 Geometry3K-601 上的可信校准实验。

条件	正确数	总数	准确率
raw	325	601	54.08%
oracle_full	318	601	52.91%
oracle_topk6_cautious	325	601	54.08%
oracle_corrupt_trusted	314	601	52.25%




图 3: 完整 Geometry3K 信任实验。干净 oracle predicates 并不自动提升 Qwen3-VL；谨慎筛选版本与 raw 持平；被包装成可信的错误结构伤害最大。

6 答案诱导压力测试

该实验测试结构化语言是否会把 MLLM 带向某个选项。结果非常明显：当 trusted structure 暗示 A/B/C/D 时，模型跟随率约为 91–96%；当这个 trusted structure 被故意设为错误答案时，准确率降到 7.5%。加入 self-verification 后，跟随率降到 49.5%，准确率恢复到 31.5%，但仍远低于 raw。这说明结构化语言在“可信事实”的包装下可以覆盖模型自身的视觉判断。

7 定性案例

在题 2783 中，目标是弧 $\widehat{JK}$ 的长度，oracle logic 包含圆心和角度信息，construction-aware route 能把模型引向弧长公式。题 2556 中，题干说明可见切线段可视为切线，construction cue 会提示等切线长和半径垂直切线等关系，因此有帮助。相反，题 2565 要求 $\tan X$ ，raw 视觉推理本来正确，但额外结构可能让模型转向错误比值。题 2539 是更复杂的圆关系，部分结构事实会使模型误用弧/弦定理，从而破坏 raw-correct 答案。

表 4: Answer-steering stress test。

条件	正确数	总数	准确率
raw	102	200	51.0%
clean_topk6_cautious	103	200	51.5%
steer_wrong_trusted	15	200	7.5%
self_verify_wrong	63	200	31.5%





图 4: 答案诱导压力测试。当结构化语言强烈暗示某个选项时, Qwen3-VL 经常跟随它。错误 trusted steering 条件下, 模型约 90% 跟随错误结构, 准确率降到 7.5%。

8 当前证据支持什么

实验支持四个具体结论。

1. **GDP-style 自动结构在我们的复现设置中不够。** Geometry3K-300 上, image+GDP 为 51.33%, 低于 raw 的 52.67%。
2. **目标条件化 construction plan 有潜力。** 同一数据上, construction_plan 达到 55.67%, 相对 raw 的 pairwise net 为 +9。
3. **oracle 结构本身也不充分。** 完整 601 题上, Geometry3K oracle formal logic 低于 raw, 说明瓶颈不只是缺少符号事实。
4. **可信校准是核心。** corrupted 或 answer-steering 结构化语言会强烈带偏 Qwen3-VL, 因此后续系统需要 fact-level verification、relevance scoring 和 conflict handling。



(a) 2783: 弧长。raw 错, construction plan 对。 (b) 2556: 切线长度。构造提示有帮助。 (c) 2565: 正切比。raw 对, 结构提示可能干扰。 (d) 2539: 弧/弦关系。多个结构版本有害。

图 5: flip analysis 中的 Geometry3K 样例。相同类型的结构信息可能有帮助, 也可能有害, 取决于被选中的事实是否匹配题目的目标定理路线。

9 从 oracle plan 到自动生成

当前效果最好的语言依赖 oracle 标注。要把它变成真实方法, 下一步需要训练一个自动 generator/parser, 从图像、题干和选项预测 construction-aware intermediate language。

训练目标。 使用 Geometry3K 标注生成 pseudo-label, 包括结构事实、辅助构造候选、定理路线和 trust metadata。目标格式应包含 predicate 文本, 以及简洁的来源、置信度、目标相关性和冲突标志。

模型候选。 可以训练轻量 seq2seq parser, 也可以使用“两阶段系统”: 先做视觉关系检测, 再用 LLM planner 组织定理路线。实际远程服务器方案是: 微调一个 2B-7B VLM 或 adapter 生成 pseudo-label, 再用冻结的 Qwen3-VL 做下游求解评测。

评测协议。 后续实验应保持相同 raw baseline, 并比较 raw、GDP automatic、oracle construction plan、generated construction plan、generated plan with trust filter、generated plan with conflict self-verification。主指标除了准确率, 还必须看相对 raw 的 pairwise flips。一个 generated 方法只有在保留 construction-plan wins、同时减少 structure-induced losses 时才算有说服力。

风险控制。 当前证据表明模型很容易被误导文本带偏, 所以 generator 不应该只优化“输出更多 predicates”。更合理的目标是 calibrated selective exposure: 少量、更可靠的事实, 比长而噪声多的语言更有价值。

10 自动生成器原型

我们实现的第一步自动化是一个 text-to-text generator:

question + choices + GDP parse $\rightarrow$ construction-aware intermediate language.




图 6: 自动化原型流程。模型从 GDP 自动解析学习生成 oracle-derived construction-plan pseudo-label。下游评测在同一 200 题上比较 raw、GDP 和 generated plan。

表 5: 远程 T4 服务器上的生成器训练设置。

项目	设置
基础模型	Qwen3-1.7B causal LM
适配方式	4-bit LoRA, 17.4M 可训练参数
输入	question + choices + GDP-4B automatic parse
目标	oracle-derived <code>construction_plan</code> pseudo-label
训练划分	264 train / 36 validation
优化步数	264
最终验证 loss / perplexity	0.213 / 1.237
最佳记录验证 loss	step 90 左右为 0.137
held-out 格式完整性	30 例上 section completeness = 1.000
held-out 定理 cue overlap	30 例上 0.902

输入使用 GDP-4B 自动 diagram parse，而不是 Geometry3K oracle predicates。训练目标是上文规则生成的 oracle-derived `construction_plan` pseudo-label。因此，这个模型本质上是一个“从噪声自动 parser 输出到定理导向 construction language 的翻译与修复器”。

观察到的行为。 训练后的 generator 能稳定输出 known facts、auxiliary construction candidates、theorem route 和 execution guard 等 section，也会根据题型调整定理提示，例如圆/切线题会给出 circle/tangent cues，直角三角形题会给出 perpendicular/Pythagorean cues。但定性样例也显示，事实级细节仍可能出错：点名、边长和关系参数可能以看似合理但错误的形式被复制。这正是 trust experiments 预测的失败模式，所以后续应加入轻量 verifier，在暴露给 Qwen3-VL 前删除不被标签或度量支持的可疑事实。

11 Generated Plan 下游评测

我们在同一 200 道有 GDP parse 的 Geometry3K 题上比较三个条件：raw image-question input、image+GDP、image+generated construction plan。generated plan 得到 $108/200 = 54.0\%$ ，高于 raw 的 $106/200 = 53.0\%$ 和 GDP 的 $104/200 = 52.0\%$ 。pairwise flips 比 1 个百分点的平均提




图 7: GDP-to-plan LoRA generator 的训练曲线。模型很快学会分 section 的 construction-plan 格式。后期训练 loss 继续下降, 但 validation loss 略有过拟合, 因此后续可以比较 final checkpoint 和更早 checkpoint 的下游效果。

表 6: 200 道 Geometry3K 题上的下游评测。

条件	正确数	总数	准确率
raw	106	200	53.0%
image+GDP	104	200	52.0%
image+generated construction plan	108	200	54.0%

升更有解释力: GDP 修正 5 个 raw 错误, 但破坏 6 个 raw 正确答案; generated plan 同样修正 5 个 raw 错误, 但只破坏 3 个 raw 正确答案。因此, 当前 generator 还没有复现 oracle construction-plan 的更强提升, 但它确实把 GDP 信号从轻微有害变成了轻微有益。

例子。 Generated construction plans 修正了一些 raw 错误, 包括: 2771、2971、2887。它也仍会伤害一些 raw-correct case, 包括: 2873、2717、2561。这与定性观察一致: generator 通常能给出有用的 theorem-route guidance, 但偶尔会加入看似合理的错误事实, 从而把 MLLM 引向错误方向。

12 GDP 到定理路线生成器

Construction-plan 的结果说明, 有用的中间语言不一定是更长的图形事实列表。真正有帮助的部分可能是更紧凑的 theorem-route prior: 这道题大概率需要哪些关系和定理。于是我们实现了第二套自动流程:

题图 → GDP-4B 自动解析, 题干 + GDP parse → 定理路线, 图像 + 题干 + route → Qwen3-VL 答案.




图 8: 200 道 Geometry3K 题上的 Qwen3-VL 准确率。自动生成的 construction plan 是我们实验中第一个在同一 split 上略高于 raw 和 GDP 的非 oracle 结构语言。

表 7: generated plan 与 GDP 相对 raw 的 pairwise flips。

条件	修正 raw 错误	破坏 raw 正确	净变化
image+GDP	5	6	-1
generated construction plan	5	3	+2

Route generator 使用 FormalGeo 训练，因为 FormalGeo 中包含形式化题目描述和 theorem sequence。训练时，输入是题干加 GDP-4B 对图像的自动解析；目标是把数据集 theorem sequence 转换成简洁的 theorem-route prompt。下游测试时，Qwen3-VL 仍然接收原始图像。Generated route 只被包装成“求解假设”，prompt 中明确要求模型根据图像和题干验证路线，而不是盲信路线。

Pairwise 结果更关键：generated theorem route 修正 16 个 raw 错误，破坏 10 个 raw 原本正确的样例，66 题两者都正确，58 题两者都错误，净收益为 +6。相比前面的 200 题 generated construction-plan 结果，这个信号更清楚，因为 route generator 使用的是显式 theorem-sequence 监督，而不仅是规则生成的 pseudo-label。

12.1 安全紧凑路线实验

Geometry3K-150 实验说明 route hint 可能有帮助，但也暴露了一个问题：route generator 有时会重复同一个定理很多次，或者给出过于自信但和题目目标不匹配的路线。因此，我们又训练了两个 route generator，并在 200 道 Geometry3K held-out 题上评测 6 个变体。第一个是 **compact_route**，训练目标是最多输出 3 个去重后的 theorem step；第二个是 **confidence_route**，额外输出 route quality 字段，但实验中它过于保守，几乎把所有路线都标成 low confidence。

这个结果支持一个更细的结论：有用的不是“任意 route”，而是短、去重、目标相关的 route。旧




图 9: 相对 raw 的 pairwise flips。GDP 的净变化为负；generated construction plan 修正 5 个 raw 错误，只破坏 3 个 raw 正确样例。




图 10: 自动定理路线流程。GDP-4B 提供自动 parse；小型 LoRA 模型把 parse 和题干映射为可能的 theorem route；Qwen3-VL 接收原图和该 route 进行解题。

route generator 达到 54.5%，但破坏 10 个 raw-correct 答案；compact generator 达到 56.0%，且只破坏 4 个。硬性的 QC 过滤确实把 loss 从 4 降到 3，但也过滤掉了一部分本来有帮助的 route，使 win 从 12 降到 7，准确率从 56.0% 降到 54.0%。这说明后续信任控制不应只是简单 discard，而应训练更细粒度的 verifier 或 route rewriter。

Route quality 统计解释了这个现象。旧 route 的平均步数为 2.985，最大步数达到 30，并且存在同一定理重复多次的样例。compact route 的平均步数降到 1.285，最大步数被限制为 3。confidence-aware generator 虽然最大步数只有 4，但把 192/200 条路线标成 low confidence，导致 confidence label 太保守，难以作为有效选择器。实际经验是：在源头进行去重、长度约束和目标绑定，比在生成后追加粗粒度 confidence tag 更有效。

FormalGeo checkpoint 与 Geometry3K-150 指向同一方向，但必须谨慎解读，因为实验尚未完成。它当前的价值是诊断性的：generated route 在下游阶段并不是直接复制 oracle route，而且在更难的形式几何题上也可能优于 image-only。等远程 run 完成后，应把这张表替换成 200 题最终汇总。

表 8: GDP-to-theorem-route generator 训练设置。

项目	设置
训练来源	FormalGeo theorem sequences
已解析图像	900 张 FormalGeo 图由 GDP-4B 自动解析
基础模型	Qwen3-1.7B causal LM
适配方式	LoRA SFT
输入	question + GDP-4B automatic parse
目标	concise theorem route + raw theorem sequence
数据划分	600 train / 100 validation / 200 downstream test
训练步数	150
最终验证 loss / perplexity	0.138 / 1.148

表 9: Geometry3K-150 上 generated theorem route 的下游结果。该实验已经完成。

条件	正确数	总数	准确率	平均耗时
image only	76	150	50.67%	7.89s
image + generated theorem route	82	150	54.67%	8.67s

具体例子。 在 `geometry3k_test_2721` 中, 题目为: 若 $PR \parallel KL$, $KN = 9$, $LN = 16$, 且 $PM = 2KP$, 求 KM 。选项为 A. 5, B. 9, C. 12, D. 15, 正确答案为 D。GDP-4B 解析出点 L, N, K, R, M, P, Q , 共线关系包括 $L, N, K, R, Q, P, K, P, M, N, Q, M, L, R, M$, 并给出 $KM \perp LM$ at M 、 $LK \perp NM$ at N 等语义关系。Route generator 输出:

Listing 2: `geometry3k_test_2721` 的 generated theorem route。

The following theorem route is a hypothesis for solving the geometry problem.

[THEOREM ROUTE]

1. Use parallel corresponding angle.
2. Use line addition.

[RAW THEOREM SEQUENCE]

1. `parallel_property_corresponding_angle(1,PR,KL,M)`
2. `line_addition(1,KN,NM)`

[USE POLICY]

- Verify each theorem against the diagram and problem text.
- Do not output the final numeric answer.

在 raw image-only 输入下, Qwen3-VL 回答 C; 加入 generated theorem route 后, 同一张图和同一题干下 Qwen3-VL 回答 D。这个例子说明中间语言并没有直接给出答案, 而是把搜索空间

表 10: 200 道 Geometry3K held-out 题上的 safe route 实验。`compact_route` 在准确率和减少 route-induced loss 上表现最好。

条件	正确数	准确率	Win	Loss
image only	104/200	52.0%	–	–
old route	109/200	54.5%	15	10
compact route	112/200	56.0%	12	4
compact route + QC	108/200	54.0%	7	3
confidence route	109/200	54.5%	14	9
confidence route + QC	107/199	53.5%	11	8

表 11: FormalGeo-200 下游测试 checkpoint。写作时该 run 仍在运行，因此这里是约 70 题完成时的 partial numbers，不是最终结果。

条件	正确数	已完成数	准确率
image only	15	70	21.43%
image + generated theorem route	23	69	33.33%
image + oracle theorem route	22	69	31.88%

收缩到 parallel-angle 和 segment-addition 这条更相关的路线。

13 局限性

这些仍是 demo-stage 实验。当前最强的 construction language 依赖 oracle 标注和规则生成 pseudo-label；第一个自动 construction-plan generator 只用了 264 个 GDP-to-plan 训练样例。新的 theorem-route generator 使用了更强的 FormalGeo theorem-sequence 监督，但目前仍是 adapter 生成提示、再交给 MLLM 解题，而不是端到端训练的 MLLM。部分结果文件只保存 correctness，没有完整模型输出，限制了更细的错误重构。GDP 复现实验也不能保证和原论文条件完全一致，包括模型选择、prompt、parser 版本和数据预处理。最后，MathVista 结果说明，几何专门的 construction cues 不一定能迁移到更广泛的视觉推理任务。

14 结论

当前最重要的结论不是“中间几何语言总能提升 MLLM”。相反，我们看到：朴素结构和自动结构经常失败，完整 oracle formal logic 也可能有害，而被包装成可信事实的错误结构会强烈误导模型。正向信号更具体：当结构语言是目标条件化、定理导向，并且来自可靠标注或 theorem-sequence 监督时，它才可能提升准确率。第一个 GDP-to-construction-plan generator 在 Geometry3K-200 上只有 +1.0 个百分点的小幅收益；新的 GDP-to-theorem-route 方向给出了更清楚的结果：compact

route 在完整 601 题 Geometry3K route 评测中把准确率从 53.74% 提高到 55.57%，并且相对旧 route generator 将 route-induced loss 从 34 降到 16。下一步应把重点放在 fact-faithful 和 trust-calibrated theorem-route generation 上，让模型保留路线提示的收益，同时减少结构语言诱发的错误。