

面向多模态几何推理的 Compact Theorem Routes

中间几何语言的选择性暴露

Anonymous Authors

2026 年 6 月

摘要

中间几何语言通常被视为多模态大模型 (MLLM) 的辅助上下文：解析题图，追加符号事实，再让 MLLM 解题。本文提出选择性暴露视角：第一，描述性结构本身不是可靠干预；第二，compact theorem route 更强，因为它把图形解析压缩成定理级行动；第三，真正关键的不是 route 格式本身，而是 route 在暴露前是否经过筛选和信任校准。基于 Geometry3K、PGPS9K 和 GeoQA 的实验显示，GDP-style 结构事实和未筛选 oracle predicates 都可能无法提升 raw image solving。相比之下，定理路线本身有价值：在 GeoQA271 上，generated route guidance 将 Qwen3-VL-8B 从 30.63% 提升到 38.01%，verified-policy route 达到 40.59%。FormalGeo oracle-route 检查将 29.00% 提升到 41.50%，但由于 FormalGeo 与 GeoQA 的难度和标注格式不同，本文仅将其作为定性 sanity check。关键问题转向校准：在同一个 GeoQA271 划分上，verified-policy route 仍然最好，而 equation 和 hybrid candidates 优于 direct route。这支持一个级联策略：优先筛选 route；当 route 置信度不足时，把它降级为目标绑定的 theorem-equation candidates；如果置信度仍低，则退回 raw image solving。我们还发现 compact route 可以为小型 VLM 提供推理时定理规划辅助：InternVL3-2B 从 15.75% 提升到 31.75%，而强 8B 模型收益较小。

1 引言

图形几何推理是多模态模型的高密度压力测试：模型必须识别几何实体，绑定标签与数量，选择适用定理，并计算目标值。因此，经典 neuro-symbolic 系统通常会先将题图和文本转成 formal language，再进行求解。Inter-GPS 将几何题解析为形式化表示并进行可解释推理 [1]；GeoQA 提出了面向几何数值推理的多模态问答基准 [2]；FormalGeo 系统化组织几何条件、定理序列和可验证求解轨迹 [3]；DFE-GPS 和 Geoparsing 等近期工作进一步面向 MLLM 时代重新研究图形形式化与统一形式语言解析 [4, 5]。

这些工作自然引出一个假设：如果 MLLM 在原图之外还能看到结构化几何描述，解题准确率应该提高。我们的实验说明，这个假设并不完整。中间语言不是被动上下文，而是对模型推理轨迹的干预。一个看似正确的结构事实可能与目标量无关；一条定理路线可能使用真实定理，却服务于错误子问题；一个过于权威的 route 还可能覆盖模型本来正确的视觉判断。因此，核心问题不是“是否给中间语言”，而是暴露什么数学单元，以及在什么可靠性条件下暴露。

本文研究三个逐渐接近解题动作的单元：结构事实、紧凑定理路线和定理-方程候选。实验证据显示出清晰层次：结构事实往往不够，因为它只描述“看见了什么”，没有描述“应该怎么做”；compact route 更强，因为它把解析结果压缩成定理级行动；定理-方程候选并不是为了替代 verified route，而是在 route 级验证不可靠时，把 route 转换成目标绑定、前提可检查的小规模选择问题。

本文的贡献如下：

- **给出无条件结构暴露的反例。**我们展示 GDP-style 自动结构和未筛选 oracle predicates 在作为普通上下文追加时，都可能无法提升 Qwen3-VL-8B。
- **把 compact route 定位为定理级压缩和规划辅助。**我们展示 generated route 可以把图形解析压缩为面向目标的定理行动，并在 GeoQA 与跨模型 PGPS9K+Geometry3K 测试中提升下游 MLLM 解题准确率，尤其对较小 VLM 更明显。
- **用 win-loss 视角分析 route 可靠性。**我们不只报告 accuracy，而是统计 route 相对 raw image solving 修正了多少错误、又破坏了多少原本正确的答案。
- **提出选择性暴露级联。**系统应先验证 route 可靠性；若验证不足，再将 route 降级为 theorem-equation candidate；若仍不可信，则隐藏中间语言。

2 作为数学接口的中间语言

本文不是简单替换 prompt 模板。核心问题是上游解析器或 route generator 与下游 MLLM 之间的计算契约。三类中间语言承担不同数学角色：

- **结构化事实**描述图中有什么：点、线、角度、平行、垂直、切线等关系。
- **定理路线**描述可能怎么做：应该用哪些几何事实、按什么大致顺序使用。
- **候选定理-方程**同时暴露候选 theorem binding 和可执行方程骨架，迫使模型选择前提与目标和已知条件匹配的规则。

候选式界面更接近 formal solver 中的 theorem application：定理只有在前提能匹配到已知事实、结论又连接到目标量时才应被使用。这个视角解释了为什么某些 route 即使提到真实定理，仍然会误导模型：定理真实性弱于目标有用性。不过，同划分实验也说明 verified route 当前强于 candidate 转换本身；因此 candidates 应被理解为不确定 route 的安全降级方案，而不是 verification 的替代品。

3 相关工作与问题空缺

形式化几何求解。 Inter-GPS 和 FormalGeo 等形式化求解系统强调显式几何条件、定理应用和符号验证 [1, 3]。这些工作说明结构化数学状态对几何推理很重要。本文不同之处在于，我们不假设已经拥有完整符号求解器，而是研究部分中间语言应如何暴露给仍然读取原始图像的 MLLM。

表 1: 中间几何语言的三层接口层级。本文并不是说后一层完全替代前一层，而是每一层都针对上一层的具体失败模式。

层级	暴露对象	解决的失败模式	主要实验
描述性事实	点、线、关系等解析事实	补充感知，但不告诉模型怎么做	Geometry3K 结构实验
Compact route	短定理行动序列	补充定理规划，但可能目标错配	GeoQA271 与跨模型实验
定理-方程候选	定理绑定 + 方程骨架	route 验证较弱时的安全降级	GeoQA220/271 candidates

表 2: 与代表性几何和视觉数学推理工作的定位比较。已有工作主要改进解析、形式化求解、视觉语言预训练或指令微调；本文关注已经生成的中间表示何时应该暴露给 MLLM。

工作方向	形式结构	定理路径	MLLM 求解	暴露校准
Inter-GPS / FormalGeo [1, 3]	✓	✓	–	–
GDP / Geoparsing [7, 5]	✓	–	optional	–
DFE-GPS / GeoX [4, 8]	✓	partial	✓	–
MAVIS / GeoDANO [9, 10]	implicit	implicit	✓	–
本文	✓	✓	✓	✓

几何图解析与多模态基准。 GeoQA、Geometry3K 和 MathVista 从不同标注体系评估视觉数学推理 [2, 1, 6]。DFE-GPS 和 Geoparsing 等近期工作提升了从图形到 formal language 的上游转换能力 [4, 5]。这些解析器使中间语言暴露变得更可行，但并没有回答下游 MLLM 何时应该相信这些文本。我们的实验显示，parser output 的作用取决于目标绑定和暴露策略：它可能帮助，也可能无效或有害。

MLLM 的中间推理接口。 很多 MLLM 方法会通过分解、rationale、program 或 symbolic hint 改善推理。但在几何任务中，中间对象并不只是自然语言推理链，而是对应定理前提、实体绑定和方程关系。因此，盲目执行 route 特别容易带来风险。本文将中间语言视为需要校准的干预，并用 pairwise win/loss 同时衡量帮助和伤害。

4 实验协议

下游求解器使用 Qwen3-VL-8B。主要数据集是 Geometry3K [1] 和 GeoQA [2]；MathVista 仅作为额外视觉数学参考 [6]。GDP-style 结构由几何图解析方向的 parser 生成，其方向对应 Geoparsing 等工作 [5]。route 实验中，我们使用已保存的 Qwen3-1.7B LoRA generator，将结构化几何输入映射成 theorem-route 风格输出，然后再把 route 转成不同的下游接口。该 route generator 在




图 1: 核心发现与机制。compact route 将几何解析转化为定理级行动。在多个下游设置中, image+compact-route 输入能够提升 raw image solving; 但 route 必须被视为目标绑定的数学接口, 而不是可信自由文本。

FormalGeo-style route data 上训练, 并在 held-out 或跨数据集下游样本上评测; 本文没有在用于 GeoQA 评测的样本上继续微调该 generator。

划分说明。 GeoQA120、GeoQA220 和 GeoQA271 是同一个过滤后 GeoQA 顺序上的确定性前缀子集, 过滤条件是答案能解析为简单数值。因此 GeoQA120 包含于 GeoQA220, GeoQA220 包含于 GeoQA271。数量不同来自实验预算和变体数量不同, 而不是不同采样规则: 271 题用于 route policy, 120 题用于便宜地比较多种 presentation interface, 220 题用于更重的 theorem-equation candidate 评测。这种嵌套关系也应被视为局限: 最干净的后续比较应在同一个固定划分上运行所有接口。

评测同时报告 accuracy 和相对 raw image baseline 的 pairwise flips。win 指 raw 错、增强方法对; loss 指 raw 对、增强方法错。这个指标很关键, 因为一种方法即使平均准确率提高, 也可能引入新的 route-induced error。

形式化地, 令 x_i 表示图像、题干和选项, y_i 表示标准答案, z_i 表示被暴露的中间对象, 例如 route 或 candidate list。令 $f_0(x_i)$ 为 raw image prediction, $f_z(x_i, z_i)$ 为暴露中间对象后的 prediction。

单题效果定义为

$$\Delta_i(z) = \mathbf{1}[f_z(x_i, z_i) = y_i] - \mathbf{1}[f_0(x_i) = y_i]. \quad (1)$$

其中 $\Delta_i = 1$ 是 win, $\Delta_i = -1$ 是 loss, 整体增益为

$$\text{Gain}(z) = \frac{1}{N} \sum_i \Delta_i(z) = \frac{W(z) - L(z)}{N}. \quad (2)$$

这个指标说明, 即使平均增益较小, route 仍可能揭示一个高价值但校准不足的干预通道。

verified-policy route 的操作定义。 本文主表中的 ‘verified-policy’ 是轻量 route-level heuristic, 而不是训练得到的 verifier。具体实现中, 我们先从 route 文本中抽取 generated theorem sequence。无法抽取 theorem sequence 的 route 直接 reject; 超过八步的 route, 或同一个 theorem name 重复五次及以上的 route, 会被标记为 low confidence。对剩余 route, 我们检查 theorem family 是否匹配目标类型, 以及结构化解析中是否存在对应支持谓词, 例如 parallel、right-triangle 或 similar-triangle 证据。高置信 route 会连同显式 use-policy 一起暴露给 MLLM; 中置信 route 会附带风险信号; 低置信 route 仍可见, 但只作为弱提示, 要求模型优先依赖图像; reject route 则隐藏。它不同于 *critique-first*: 后者是在 route 已经暴露给 MLLM 后, 让 MLLM 自己批判 route。后文的 strict-gate ablation 是另一套更保守的规则; 其较低准确率说明硬过滤会丢掉有用信号。

在 GeoQA271 上, 这个 policy 的分层结果是: high 244 题、medium 2 题、low 12 题、reject 13 题。对应的分层准确率分别是 101/244 (41.39%)、1/2 (50.00%)、7/12 (58.33%) 和 1/13 (7.69%)。这些数值应只被看作操作审计, 因为 medium 和 low 子集都很小。本文正文报告的 110/271 是整体验证后的加权准确率。另需说明: low-confidence 在此实验中并不等于纯 raw fallback; route 仍以弱提示形式可见, 只有 reject 才完全隐藏。

候选转换。 GeoQA 实验中的 theorem candidates 和 equation candidates 都不是由更强的外部 LLM 重新生成, 而是从同一个 generated route source 里用确定性的规则抽取得到。我们先解析 route 中的 theorem 调用, 再按出现顺序去重 theorem name, 并把已知 theorem name 映射到固定的自然语言描述模板。equation candidates 则来自一组固定方程骨架模板, 例如三角形内角和、平行线角相等、勾股关系、相似三角形比例以及圆中角关系。目标类型通过题干中的关键词推断, 如 angle、length、area、perimeter 等。如果 route 无法解析出可用 theorem, 则候选界面退回到 “none of the above / 从原图作答”。这样的设计是为了隔离暴露格式的作用, 而不是引入另一模型的额外推理能力。

5 发现一：只有结构事实还不够

在 Geometry3K-300 子集上, 直接追加 GDP 自动结构没有提升 Qwen3-VL。raw image solving 为 158/300, image+GDP 为 154/300。从 pairwise 看, GDP 修正 10 个 raw 错误, 但破坏 14 个 raw 原本正确的题。oracle-guided construction language 更好, 达到 167/300; 但它不是平铺解析结果, 而是目标条件化、定理导向的语言。

表 3: 主张与证据对应表。每个核心主张都对应具体实验，并给出除 accuracy 外的诊断指标。

主张	主要证据	诊断指标
描述性结构并不自动有用。	Geometry3K-300 与 Geometry3K-601 trust experiments。	accuracy 与 raw-vs-structure flips。
theorem route 能帮助，但也会破坏 raw 本来正确的答案。	GeoQA271 route 实验和 win/loss 分解。	pairwise wins、losses、net gain。
compact route 是有效的定理级压缩。	GeoQA271、Geometry3K-601 与跨模型 PGPS9K+Geometry3K 验证。	accuracy、win/loss 与分模型增益。
选择性暴露是级联策略，而不是单一最佳格式。	GeoQA120/220/271 exposure experiments。	accuracy、win/loss 与相对 direct route 的 net gain。




图 2: 代表性中间语言暴露策略的 pairwise win/loss 分解。仅看 accuracy 会掩盖一种方法究竟是在修正 raw 错误，还是用新错误抵消这些修正。

完整 Geometry3K-601 trust experiment 进一步说明了这一点。full oracle predicates 为 318/601，低于 raw 的 325/601；cautious top-6 版本与 raw 持平。这排除了一个过于简单的解释：瓶颈并不只是“缺少符号事实”。

6 发现二：定理化语言更强，但有风险

定理路线比普通结构事实更有用，因为它更接近数学推理。在 GeoQA271 上，generated route guidance 将 Qwen3-VL 从 83/271 提高到 103/271；轻量 verified-policy 版本进一步达到 110/271。但是，direct route 仍然造成损失：22 个 raw-correct case 在 route guidance 下变错。

这正是目前实验中最关键的矛盾：route language 的数学价值是真实存在的，但 MLLM 也会过度跟随它。单独的 FormalGeo oracle-route 检查把“路线本身有价值”这件事说得更清楚：在 200 道

表 4: Geometry3K-300 对比。所有结构化变体都保留原图。

变体	结构来源	正确数 / 总数	准确率
raw	无	158 / 300	52.67%
image+GDP	GDP-4B 自动解析	154 / 300	51.33%
structured facts	Geometry3K oracle predicates	161 / 300	53.67%
construction plan	oracle predicates + 定理提示	167 / 300	55.67%




图 3: 结构并不会自动有用。GDP 自动结构低于 raw; construction-aware theorem language 更强。

FormalGeo 样本上, dataset-annotated route 将 image-only Qwen3-VL 从 58/200 提升到 83/200。由于 FormalGeo 与 GeoQA 在题目难度、标注格式和 theorem sequence 构造方式上不同, 本文只把它作为辅助 sanity check, 完整表格放在附录 A。

route generator 有时会重复某个定理, 选择局部看似合理但与目标无关的定理, 或者给出缺少图像支撑的路线。下游 MLLM 可能因此自信地解错问题。

7 自动 GDP-route 流程中的 Compact Route

前面的 route 实验说明定理化语言有潜力, 但还不能证明最早的自动流程本身有效:

image $\rightarrow$ GDP-4B structure $\rightarrow$ route generator $\rightarrow$ MLLM solver.

因此, 我们在 400 道混合题上复测完整流程: 200 道 PGPS9K 和 200 道 Geometry3K。所有 route 都由 GDP-4B 自动结构化语言生成, 再输入微调后的 Qwen3-1.7B route generator。下游求解器为 Qwen3-VL-8B; 所有变体都保留原始图像和题干。

图 4 展示了最积极的模型区间: 较小 VLM 明显受益于定理级压缩。Qwen2.5-VL-3B 从 37.75% 提升到 39.75%, InternVL3-2B 从 15.75% 提升到 31.75%。这个过程不更新下游模型参数; compact route 更准确地说是一种推理时规划辅助: 上游生成的 theorem planning 以文本形式提供给内部

表 5: Geometry3K-601 可信校准实验。oracle structure 不是 plug-and-play 的提升。

变体	正确数 / 总数	准确率	解释
raw	325 / 601	54.08%	image-only baseline
oracle_full	318 / 601	52.91%	未筛选结构过多
oracle_topk6_cautious	325 / 601	54.08%	筛选后恢复到 raw
oracle_corrupt_trusted	314 / 601	52.25%	错误可信事实有害

表 6: GeoQA271 route 实验。route 提高平均准确率，但仍引入 route-induced loss。

变体	正确数 / 总数	准确率	相对 raw 的 win	相对 raw 的 loss
image only	83 / 271	30.63%	—	—
image + generated route	103 / 271	38.01%	42	22
image + verified-policy route	110 / 271	40.59%	45	18

几何规划能力较弱的下游模型。表 8 则说明其在强求解器上的限制。standard GDP-route 加质量控制将 Qwen3-VL-8B 的混合划分仅从 48.25% 提升到 49.50%，相对 raw 有 31 个 win 和 26 个 loss。收益主要来自 Geometry3K：route+QC 将 44.5% 提升到 47.5%。该 Qwen3-VL-8B 划分中的 compact route 并非统一更强。因此，该效果是模型相关的，而不是普适的；当强 VLM 已能直接从图像解出较多题时，收益会缩小。

因此，正确结论不是“compactness 本身解决问题”。compact route 在暴露缺失定理行动时有效，但仍然需要校准。本轮 400 题中，167/400 条 compact route 会被简单质量控制 discard，315/400 被标记为 low-confidence，平均提取长度为 5.58 个 theorem steps。这推动了级联式接口：高置信 route 直接作为 verified hint；route 级验证不足时，降级为目标绑定 theorem-equation candidates；如果两者都不可靠，则隐藏中间语言。

定性地看，route-induced error 有较一致的模式。win case 中，route 通常补上了从目标量到已知量之间缺失的桥梁，例如平行线角关系指向相似比，或者圆面积公式指向阴影面积计算。loss case 中，route 不一定完全错误，而可能是目标不匹配：图中真实成立的定理未必服务于题目要求的量。GeoQA220 的粗略统计显示，角度题同时占据 direct-route win 和 loss 的多数（32 个 win 中 30 个，19 个 loss 中 14 个），因此目标类型本身不能作为绑定错误的证据。本文只用这个统计说明 route 影响集中在哪里；仍需要细粒度标注来区分定理名称错误、实体绑定错误、数值计算错误，以及模型看到 route 后产生的视觉注意力转移。

8 从定理路线到定理-方程候选

为什么不能只做 route 后过滤？route 是序列级对象：即使过滤掉特别长、明显重复或低置信度的 route，剩下的 route 仍可能包含局部真实但绑定错目标的定理。不过，表 11 也说明，验证比格式转换更重要：verified-policy route 在同划分上强于所有 candidate 变体。因此更合理的表述




图 4: 跨下游 VLM 的 compact-route 验证。在 PGPS9K+Geometry3K 划分上, 同一 compact-route 通道同时提升 Qwen2.5-VL-3B 和 InternVL3-2B, 并与早期 Geometry3K-601 上的 Qwen3-VL 结果一致。InternVL2.5-2B 本轮输出无法稳定解析为数值, 因此不计入图中。

表 7: 跨下游 VLM 的 compact-route 增益。compact route 由上游生成, 并与原始图像和题干一起输入下游模型。win/loss 相对问题 image-only prediction 统计。

下游 VLM	数据集	Image only	Image+compact route	Win / loss
Qwen2.5-VL-3B	PGPS9K+Geometry3K-400	151 / 400	159 / 400	26 / 18
InternVL3-2B	PGPS9K+Geometry3K-400	63 / 400	127 / 400	72 / 8
Qwen3-VL-8B	Geometry3K-601	325 / 601	334 / 601	27 / 16

是级联策略: 第一, 能验证 route 时优先使用 verified route; 第二, 当 route 级置信度不足时, 将 route 拆成 theorem application, 检查目标类型、实体绑定和方程后果; 第三, 如果 candidate 层证据也不足, 退回 raw image solving。

因此, 我们在 120 道 GeoQA 题上做了一个小但有信息量的 trust ablation。所有变体使用同一个 route 来源, 但以不同方式交给 Qwen3-VL: 直接执行路线、先批判再使用、候选定理选择, 以及基于规则的 risk fallback。

120 题结果说明候选选择有价值, 但它并不是最终形态。我们进一步在 220 道 GeoQA 题上比较 direct route、theorem candidates、equation candidates 和 theorem+equation hybrid candidates。结果显示, 单独的定理名候选会丢失部分路线顺序信息, 而候选方程能通过计算骨架恢复一部分有效信号。

hybrid candidates 表现最好: 相对 raw 的 pairwise net 为 +17, 相对 direct route 的 pairwise net 为 +4。这说明更有用的单位不是单独的 theorem name, 而是目标绑定的 theorem-equation

表 8: PGPS9K 与 Geometry3K 上的跨数据集 GDP-route 验证。standard route 加质量控制对 Qwen3-VL-8B 有小幅收益；compact route 在单独跨模型实验中对较小 VLM 更有帮助。

route generator	数据集	image only	route	route + QC
standard route	PGPS9K-200	104 / 200	101 / 200	103 / 200
	Geometry3K-200	89 / 200	94 / 200	95 / 200
	Overall	193 / 400	195 / 400	198 / 400
compact route	PGPS9K-200	104 / 200	103 / 200	105 / 200
	Geometry3K-200	89 / 200	88 / 200	88 / 200
	Overall	193 / 400	191 / 400	193 / 400




图 5: Qwen3-VL-8B 上的跨数据集 GDP-route 验证。standard route 加质量控制带来小幅整体提升；compact-route 结果说明 route 需要校准，而不是盲目暴露。

pair。定理提供语义方向，方程提供可计算约束，两者组合比单独路线或单独定理候选更稳。但这个比较仍然只是 candidate interface 的 lower-bound 测试，而不是 oracle upper bound：GeoQA220 中所有 candidates 都由同一个 generated route source 转换而来，因此候选池仍受 route generator 质量约束。

为了避免在不同 GeoQA 子集上比较不同接口，我们又把这些暴露方式放回同一个 271 题划分上复测。结果改变了本文解释重点：可靠性控制比 candidate 格式更重要。equation 和 hybrid candidates 仍然优于 direct route，但 verified-policy route 仍然最好。theorem-only candidates 反而弱于 direct route。这说明 candidates 本身不是万能格式；它们的作用是让不确定的 route 信息更容易被检查、拒绝或部分使用。

这也意味着，candidate interface 只是 lower-bound 测试，而不是上界：GeoQA 的 candidates 都是用实验协议中描述的规则抽取器从同一个 generated route source 转换而来，因此候选池既受 route generator 质量约束，也受固定 theorem/equation 模板表约束。附录 A 中的 FormalGeo




图 6: route 带来帮助和带来伤害的代表性案例。有效 route 会把 MLLM 引向与目标直接相关的定理或计算；有害 route 往往并不“胡说”，而是绑定错了目标，或者给出过于具体但并不必要的提示，从而干扰更简单的视觉解法。

oracle-route 结果不是 GeoQA 上界，但它强化了一个定性事实：可靠 theorem route 可以有价值。更强的评测仍然需要在同一目标数据集上从标注 theorem sequence 构造 oracle candidates，并训练直接输出 theorem-equation pairs 的候选生成器。

两个 gate ablation 进一步说明了权衡关系。strict verified route 比 verified-policy 更保守：超过六步的 route 会被拒绝，同一定理重复三次及以上会被标记为风险，定理类型必须与推断出的目标类型匹配；当 route 使用 parallel、perpendicular/right-triangle 或 similar-triangle 相关定理时，解析事实中还必须出现对应前提谓词。若这些严格检查不通过，route 会被隐藏。cascade 版本使用同一个 strict gate：高置信 route 直接暴露，中置信 route 降级为 hybrid candidates，低置信 route 退回 raw image solving。这能避免部分坏 route，但也丢掉太多有用规划信号。因此，当前最好的 policy 不是最严格的 policy，而是在保留足够 route 信号的同时，用置信度和风险提示校准 MLLM 的使用方式。

表 9: GeoQA120 trust ablation。候选定理界面是该实验中最强变体。

变体	正确数 / 总数	准确率	相对 raw 的 win	相对 raw 的 loss
image only	34 / 120	28.33%	—	—
direct route	47 / 120	39.17%	22	9
critique-first route	47 / 120	39.17%	23	10
theorem candidates	49 / 120	40.83%	24	9
risk fallback	45 / 120	37.50%	20	9




图 7: GeoQA 上的 route 接口比较。候选定理选择在 120 题 trust ablation 中得到最高准确率和最高 pairwise net; verified policy 在更大的 GeoQA271 实验中也带来提升。

9 为什么候选暴露是安全接口

本文引入 candidate exposure, 并不是因为它在当前实验中超过 verified route, 而是因为当 route 级验证不可用或不确定时, direct route 非常脆弱。定理-方程候选界面改变了 route generator 和 MLLM 之间的计算契约。

- **从断言变成选择。** route 说“使用这个定理”; candidate list 说“选择前提与目标和已知条件匹配的定理”。
- **从跟随序列变成目标绑定。** 模型必须判断某个定理是在求角、求长度、求比值还是求面积。
- **从相信变成验证。** 错误候选可以被拒绝, 而不必拒绝整个中间语言通道。
- **从定理名到计算。** 候选方程要求被选定理实例化为具体数值关系, 使中间语言更接近可执行数学。

这个视角更接近 formal geometry solver 中的 theorem application: 定理应用需要把定理前提匹配到已知事实, 并把定理变量绑定到图中实体。它也解释了为什么简单 critique prompt 更弱: 让模型“谨慎一点”并没有给出明确的替代动作空间, 而定理-方程候选选择给出了。

表 10: GeoQA220 candidate-grounding 实验。候选方程和 theorem+equation hybrid candidates 均超过 direct route。

变体	正确数 / 总数	准确率	相对 raw 的 win	相对 raw 的 loss	相对 route 净变化
image only	69 / 220	31.36%	—	—	—
route direct	82 / 220	37.27%	32	19	—
theorem candidates	80 / 220	36.36%	34	23	-2
equation candidates	84 / 220	38.18%	32	17	+2
hybrid candidates	86 / 220	39.09%	36	19	+4




图 8: GeoQA220 candidate-grounding 结果。候选方程超过 direct route, theorem+equation hybrid candidates 表现最好。

10 失败模式与适用范围

当前结果的主要局限在于：GeoQA 的 candidate list 仍然是从 generated route 转换而来，而不是由完整训练的 theorem-equation selector 直接生成。这个设置是有意为之的压力测试，但也意味着下游候选池仍受到上游 route 质量的约束。如果 GDP-style parsing 漏掉关键关系或产生幻觉关系，定理-方程候选列表仍可能不完整或误导。因此，GeoQA 结果应被理解为：在固定 generated-route source 下，暴露格式本身有帮助；而不是 theorem-equation candidate 的性能上限。FormalGeo oracle-route 检查说明可靠 route annotation 可能有用，但它还不是 GeoQA oracle theorem-equation candidate。更强的评测需要从标注 theorem sequence 构造 oracle candidates，并训练直接输出 theorem-equation pairs 的候选生成器。

评测覆盖也表明，exposure policy 必须同时按数据集和模型区分。Geometry3K、PGPS9K 和 GeoQA 的标注形式、图像分布和题型并不一致；Qwen3-VL-8B、Qwen2.5-VL-3B 和 InternVL3-2B 对 route text 的反应也不同。compact route 在下游模型缺少足够几何规划能力时最有价值，但 route-induced loss 仍然存在。因此，部署时应按数据集、模型、目标类型和 route 接受状态报告结

表 11: GeoQA271 同划分暴露对比与 gate ablation。可靠性控制是当前最强干预：verified-policy route 超过所有 candidate 变体，而 strict gate 过于保守。equation 和 hybrid candidates 仍优于 direct route，说明它们更适合作为验证不足时的安全降级，而不是 verification 的替代品。

变体	正确数 / 总数	准确率	相对 raw 的 win	相对 raw 的 loss	相对 route 净变化
image only	83 / 271	30.63%	—	—	—
route direct	103 / 271	38.01%	42	22	—
strict verified route	86 / 271	31.73%	26	23	-17
cascade route candidate raw	91 / 271	33.58%	30	22	-12
verified-policy route	110 / 271	40.59%	45	18	+7
theorem candidates	99 / 271	36.53%	42	26	-4
equation candidates	107 / 271	39.48%	43	19	+4
hybrid candidates	108 / 271	39.85%	46	21	+5

果，并在有 oracle theorem labels 的数据上对比 generated candidates 与 oracle candidates。

11 方法启示：目标绑定 verifier

这些结果指向一个明确的系统架构：route-first selective exposure with candidate fallback。输入为 image、question、choices 和 GDP-style structure。系统首先对整条 generated route 打分；高置信时将 route 作为强但非 oracle 的 hint 暴露；中等置信时将 route 拆成 theorem-equation candidates；低置信时隐藏中间语言。

实际可用的候选级 verifier 应检查四类条件：定理是否匹配目标类型，绑定实体是否与题干和解析事实重合，定理必要前提是否被 parsed fact set 覆盖，以及方程后果是否直接求解目标量。本文不为这些检查指定手写固定权重。GeoQA271 同划分上的 strict rule-gate ablation 说明了原因：strict verified route 只有 86/271 (31.73%)，route-candidate-raw cascade 为 91/271 (33.58%)，都低于轻量 verified-policy route 的 110/271 (40.59%)。粗糙规则会拒绝有用 route，也仍可能放过弱 route。因此，可部署的级联策略应把这些检查与 learned target-binding verifier 结合：

- route 高置信度：暴露 verified route 作为强提示；
- route 中等置信度：展示定理-方程候选，让 MLLM 自己选择；
- 低置信度：隐藏中间语言，退回 raw image solving。

下一步应使用 pairwise 标签训练并评测 verifier：raw wrong 且 route correct 标为 USE-ROUTE，raw correct 且 route wrong 标为 REJECT-ROUTE。因此，本文原则应表述得更精确：中间几何语言在定理化、经过验证并选择性暴露时才稳定有用；candidate selection 是 route 级验证不足时的安全接口。

12 结论

我们的核心结论不是“结构化语言没用”，也不是“route guidance 一定有用”。证据支持更精确的说法：几何中间语言只有从描述性结构转向紧凑的定理级行动后，才更可能帮助 MLLM，但行动级语言必须选择性暴露。compact route 提升 GeoQA，并且对较小 VLM 有明显帮助，可以作为推理时定理规划辅助。它的限制是可靠性，而不是有用性。因此，更实际的方向是级联暴露：先验证 route；如果验证不足，再转化为目标绑定 theorem-equation candidates；如果置信度仍低，则隐藏中间语言并依赖 raw image solving。

A FormalGeo Oracle-Route 辅助检查

表 12 给出正文提到的 FormalGeo oracle-route 检查。它只作为定性 sanity check，而不是与 GeoQA 的直接比较，因为 FormalGeo 的题目难度、标注格式和 theorem sequence 构造方式均不同。

表 12: FormalGeo oracle-route 定性 sanity check。

变体	正确数 / 总数	准确率	相对 raw 的 win	相对 raw 的 loss
image only	58 / 200	29.00%	—	—
image + oracle theorem route	83 / 200	41.50%	32	7

参考文献

- [1] Pan Lu, Ran Gong, Shibiao Jiang, Liang Qiu, Siyuan Huang, Xiaodan Liang, and Song-Chun Zhu. Inter-GPS: Interpretable geometry problem solving with formal language and symbolic reasoning. In *Proceedings of ACL-IJCNLP*, 2021.
- [2] Jiaqi Chen, Jianheng Tang, Jinghui Qin, Xiaodan Liang, Lingbo Liu, Eric Xing, and Liang Lin. GeoQA: A geometric question answering benchmark towards multimodal numerical reasoning. In *Findings of ACL*, 2021.
- [3] Ming-Liang Zhang, Fei Yin, Yunsong Zhou, and Cheng-Lin Liu. FormalGeo: An extensible formalized framework for olympiad geometric problem solving. *arXiv preprint arXiv:2310.18021*, 2023.
- [4] Ming-Liang Zhang, Fei Yin, Yunsong Zhou, and Cheng-Lin Liu. Diagram formalization enhanced multi-modal geometry problem solving. *arXiv preprint arXiv:2409.04214*, 2024.
- [5] Peijie Wang, Ming-Liang Zhang, Jun Cao, Chao Deng, Dekang Ran, Hongda Sun, Pi Bu, Xuan Zhang, Yingyao Wang, Jun Song, Bo Zheng, Fei Yin, and Cheng-Lin Liu. Geoparsing:

- Diagram parsing for plane and solid geometry with a unified formal language. *arXiv preprint arXiv:2604.11600*, 2026.
- [6] Pan Lu, Hritik Bansal, Tony Xia, Jiacheng Liu, Chunyuan Li, Hannaneh Hajishirzi, Hao Cheng, Kai-Wei Chang, Michel Galley, and Jianfeng Gao. MathVista: Evaluating mathematical reasoning of foundation models in visual contexts. *arXiv preprint arXiv:2310.02255*, 2023.
- [7] Ming-Liang Zhang, Fei Yin, Yuxuan Hao, and Cheng-Lin Liu. Plane geometry diagram parsing. In *Proceedings of IJCAI*, 2022.
- [8] Renqiu Xia, Mingsheng Li, Hancheng Ye, Wenjie Wu, Hongbin Zhou, Jiakang Yuan, Tianshuo Peng, Xinyu Cai, Xiangchao Yan, Bin Wang, Conghui He, Botian Shi, Tao Chen, Junchi Yan, and Bo Zhang. GeoX: Geometric problem solving through unified formalized vision-language pre-training. In *Proceedings of ICLR*, 2025.
- [9] Renrui Zhang, Xinyu Wei, Dongzhi Jiang, Ziyu Guo, Yichi Zhang, Chengzhuo Tong, Jiaming Liu, Aojun Zhou, Bin Wei, Pan Lu, Kai-Wei Chang, Yu Qiao, Peng Gao, and Hongsheng Li. MAVIS: Mathematical visual instruction tuning with an automatic data engine. In *Proceedings of ICLR*, 2025.
- [10] Seunghyuk Cho, Zhenyue Qin, Yang Liu, Youngbin Choi, Seungbeom Lee, and Dongwoo Kim. GeoDANO: Geometric VLM with domain agnostic vision encoder. *arXiv preprint arXiv:2505.17856*, 2025.